Análise de Evasão, Conclusão, Trancamentos e Tempo de Permanência no Curso de Sistemas de Informação da EACH-USP (2005–2025)

Estudo quantitativo com análise de sobrevivência e modelagem preditiva

João Fontanezi
PUB - Professor Marcelo Morandini
Escola de Artes, Ciências e Humanidades
Universidade de São Paulo

Abril de 2026

Sumário

1 Introdução **3**

2 Materiais e Métodos **3**

2.1 Base de Dados . . . 3

2.2 Agrupamento das Formas de Ingresso . . . 4

2.3 Classificação de Desfechos . . . 4

2.4 Processamento e Análise . . . 5

2.5 Métodos Estatísticos . . . 5

2.5.1 Estatística Descritiva . . . 5

2.5.2 Teste Qui-Quadrado (χ^2) . . . 5

2.5.3 Teste de Mann-Whitney (U) . . . 5

2.5.4 Análise de Sobrevivência — Kaplan-Meier . . . 6

2.5.5 Regressão Logística . . . 6

3 Resultados **6**

3.1 Desfechos Gerais . . . 6

3.2 Desfechos por Grupo de Ingresso . . . 7

3.3 Motivos de Evasão . . . 7

3.4 Tempo de Curso . . . 8

3.4.1 Tempo de Conclusão . . . 8

3.4.2 Tempo até Evasão . . . 9

3.5 Créditos Acumulados . . . 10

3.6 Evasão Precoce vs. Tardia . . . 10

3.7 Evolução Temporal por Coorte (2005–2021) . . . 11

4 Análise Estatística **13**

4.1 Análise de Sobrevivência — Kaplan-Meier . . . 13

4.2 Testes de Hipóteses . . . 13

4.3 Regressão Logística . . . 14

5 Discussão **14**

6 Conclusão **15**

Apêndice: Código Python da Análise **16**

1 Introdução

A Escola de Artes, Ciências e Humanidades da Universidade de São Paulo (EACH-USP) iniciou suas atividades em 2005, adotando um modelo pedagógico baseado na resolução de problemas e no protagonismo estudantil. Ao longo de vinte anos, o curso de **Sistemas de Informação** acumulou um histórico expressivo de matrículas, formando turmas desde a sua primeira coorte.

A diversificação das formas de ingresso na USP com a incorporação do ENEM/SISU como via de entrada a partir de 2016 traz consigo uma questão relevante para o planejamento acadêmico: *existem diferenças significativas nos padrões de conclusão, evasão e tempo de permanência entre estudantes que ingressaram por diferentes meios?*

O presente trabalho tem como objetivo analisar os índices de **evasão**, **conclusão**, **trancamento** e **tempo médio de permanência** dos alunos do curso de Sistemas de Informação da EACH-USP no período de 2005 a 2025, tomando a forma de ingresso como variável de controle. A análise emprega métodos de estatística descritiva, testes de hipóteses não-paramétricos, análise de sobrevivência e regressão logística.

Os resultados esperados fornecem subsídios para o planejamento acadêmico e para o desenvolvimento de políticas de permanência estudantil, especialmente no contexto das ações afirmativas e da ampliação do acesso por meio do ENEM.

2 Materiais e Métodos

2.1 Base de Dados

A base de dados foi extraída do sistema acadêmico Júpiter da USP, cedida pela área administrativa da EACH. Contém registros de **2.849 alunos** com vínculo encerrado no curso de Sistemas de Informação, cobrindo o período de fevereiro de 2005 a janeiro de 2025. Alunos com vínculo ativo foram excluídos para garantir que todos os registros possuam desfecho definido.

Variáveis da base

Tabela 1: Descrição das variáveis da base de dados

Variável	Tipo	Descrição
`ALUNO`	ID numérico	Identificador anônimo do aluno
`STATUS`	Categórico	Estado final do vínculo (todos: ENCERRADO)
`CR_ACUMULADO`	Numérico	Total de créditos acumulados
`TIPO_INGRESSO`	Categórico	Forma de ingresso na USP
`DATA_INGRESSO`	Data	Data de início do vínculo
`DATA_ENCERRAMENTO`	Data	Data de encerramento do vínculo
`TEMPO_CURSO`	Numérico (dias)	Duração do vínculo em dias
`TIPO_ENCERRAMENTO`	Categórico	Motivo do encerramento

2.2 Agrupamento das Formas de Ingresso

A base original contém oito categorias de `TIPO_INGRESSO`. Para garantir validade estatística das análises, as categorias foram tratadas conforme sua representatividade amostral (Tabela 2).

Tabela 2: Tratamento das formas de ingresso segundo representatividade amostral

Grupo analítico	Categorias originais	n	%	Uso
FUVEST	FUVEST	2.527	88,7	Descritivo + Inferencial
ENEM_SISU	ENEM_SISU	241	8,5	Descritivo + Inferencial
TRANSF_INTERNA	TRANSF_INTERNA	45	1,6	Descritivo
TRANSF_EXTERNA	TRANSF_EXTERNA	25	0,9	Descritivo
Outros	CONV_PEC_G, GRADUADO, ENEM_USP, OLIMP	11	0,4	Descritivo
Total		**2.849**	**100,0**	

As categorias `CONV_PEC_G` ($n = 6$), `GRADUADO` ($n = 2$), `ENEM_USP` ($n = 2$) e `OLIMP` ($n = 1$) foram agrupadas na categoria **"Outros"** por possuírem amostras insuficientes para qualquer análise individual. Este agrupamento não constitui tratamento de *outliers* no sentido estatístico clássico, por não se tratarem de valores extremos em variável contínua, mas sim do reconhecimento de **subgrupos com baixa representatividade amostral**.

`TRANSF_INTERNA` ($n = 45$) e `TRANSF_EXTERNA` ($n = 25$) são mantidos separados nas análises descritivas por apresentarem resultados de interesse, mas **excluídos dos testes inferenciais** formais em razão do tamanho amostral insuficiente.

2.3 Classificação de Desfechos

A variável `TIPO_ENCERRAMENTO` foi recodificada em cinco categorias (Tabela 3).

Tabela 3: Classificação dos desfechos acadêmicos

Desfecho	**Códigos de encerramento incluídos**
Conclusão	`CONCLUSAO`
Evasão	`ABANDONO_FREQUENCIA`, `ABANDONO_MATRICULA`, `CANC_CREDITO`, `CANC_VENCIMENTO`, `DESISTENCIA`, `TRANCAMENTO`
Continua na USP	`REINGRESSO`, `TRANSF_INT`
Saída para outra IES	`TRANSF_EXT`, `CANC_OUTRA_IES`
Outros	`FALECIMENTO`, `DESCUMPRIMENTO_PEC_G`

2.4 Processamento e Análise

Todas as análises foram realizadas em **Python 3.12**, com as bibliotecas `pandas`, `scipy.stats`, `lifelines`, `scikit-learn`, `matplotlib` e `seaborn`. O tempo de curso foi convertido de dias para **semestres** (divisão por 180 dias). Coortes de ingresso a partir de 2022 ($n = 32$) foram excluídas das análises temporais por insuficiência de tempo de observação.

2.5 Métodos Estatísticos

2.5.1 Estatística Descritiva

Frequências absolutas e relativas, médias, medianas e desvios padrão de `TEMPO_SEMESTRES` e `CR_ACUMULADO`, segmentadas por grupo de ingresso e desfecho. Análises descritivas incluem todos os cinco grupos.

2.5.2 Teste Qui-Quadrado (χ^2)

Aplicado aos grupos FUVEST e ENEM_SISU para testar independência entre forma de ingresso e desfecho (evasão vs. não-evasão; conclusão vs. não-conclusão):

$$H_0 : P(\text{Evasão} \mid \text{FUVEST}) = P(\text{Evasão} \mid \text{ENEM_SISU})$$

2.5.3 Teste de Mann-Whitney (U)

Comparação das distribuições de `TEMPO_SEMESTRES` e `CR_ACUMULADO` entre FUVEST e ENEM_SISU. Não-paramétrico, adequado para distribuições assimétricas.

2.5.4 Análise de Sobrevivência — Kaplan-Meier

O estimador de Kaplan-Meier [Kaplan e Meier, 1958] modela a probabilidade de não-evasão ao longo do tempo:

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

onde d_i é o número de evasões no semestre t_i e n_i é o número de alunos em risco. Alunos que concluíram, transferiram-se ou continuam na USP são **censurados**.

O painel inferencial compara FUVEST vs. ENEM_SISU com o **teste log-rank** [Mantel, 1966]:

$$H_0 : S_{\text{FUVEST}}(t) = S_{\text{ENEM_SISU}}(t), \quad \forall\, t$$

Um segundo painel apresenta as curvas de todos os grupos como análise descritiva, sem inferência formal.

2.5.5 Regressão Logística

Modelo ajustado para estimar a probabilidade de evasão com três preditores: forma de ingresso (ENEM_SISU = 1, FUVEST = 0), tempo de curso (semestres) e créditos acumulados. Avaliado por validação cruzada estratificada de 5 dobras (AUC-ROC). Restrito a FUVEST e ENEM_SISU.

3 Resultados

3.1 Desfechos Gerais

A taxa de **conclusão** foi de 61,5% e a de **evasão** de 31,4% (Tabela 4).

Tabela 4: Distribuição geral dos desfechos

Desfecho	**n**	**%**
Conclusão	1.751	61,5
Evasão	896	31,4
Continua na USP	191	6,7
Saída para outra IES	6	0,2
Outros	5	0,2
Total	**2.849**	**100,0**

3.2 Desfechos por Grupo de Ingresso

A Figura 1 apresenta a distribuição dos desfechos para os cinco grupos analíticos. FUVEST e ENEM_SISU apresentam taxas de conclusão semelhantes (61,6% e 60,6%, respectivamente). Em termos descritivos, TRANSF_EXTERNA destaca-se com a maior taxa de conclusão (76%), e TRANSF_INTERNA com a maior taxa de evasão (40%). O grupo "Outros" (n=11) apresenta taxa de conclusão de 45,5%, mas seus resultados devem ser interpretados com cautela dado o tamanho amostral.

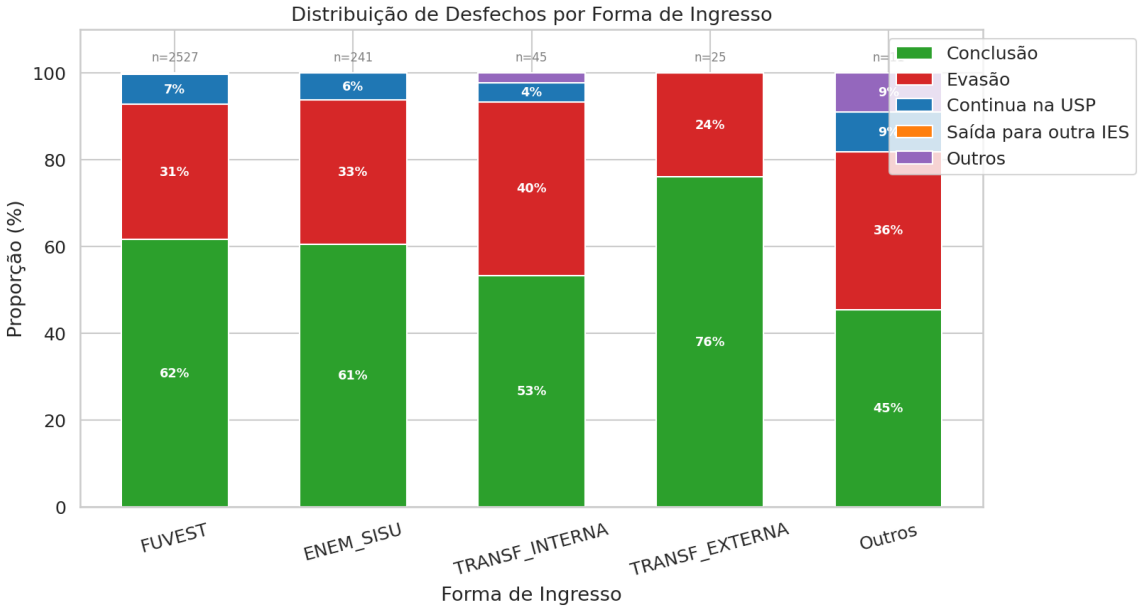

Figura 1: Distribuição de desfechos por grupo de ingresso. Os percentuais são calculados dentro de cada categoria. Os valores de n indicam o total por grupo. Testes inferenciais aplicados apenas a FUVEST e ENEM_SISU.

Tabela 5: Taxas de conclusão e evasão por grupo de ingresso

Ingresso	n	Conclusão	Evasão	Continua USP	Uso analítico
FUVEST	2.527	61,6%	31,2%	6,8%	Descritivo + Inferencial
ENEM_SISU	241	60,6%	33,2%	6,2%	Descritivo + Inferencial
TRANSF_INTERNA	45	53,3%	40,0%	4,4%	Descritivo
TRANSF_EXTERNA	25	76,0%	24,0%	0,0%	Descritivo
Outros	11	45,5%	36,4%	9,1%	Descritivo

3.3 Motivos de Evasão

Dos 896 alunos que evadiram, o motivo mais frequente foi o **cancelamento por créditos insuficientes** (43,1%), seguido de **trancamento sem reingresso** (22,5%). A Figura 2 detalha a distribuição completa, e a Figura 3 compara os motivos entre FUVEST e ENEM_SISU.

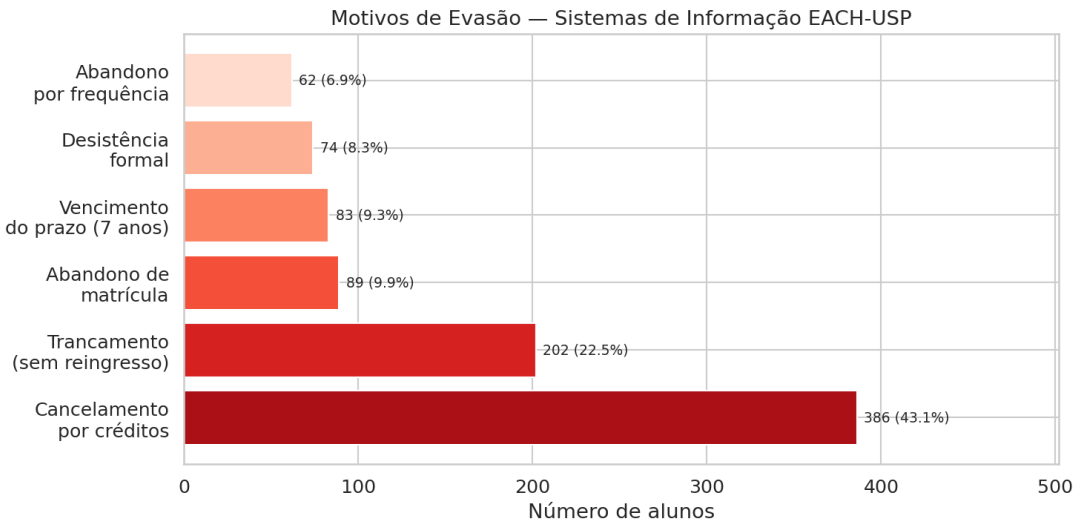

Figura 2: Distribuição dos motivos de evasão — Sistemas de Informação EACH-USP (n=896).

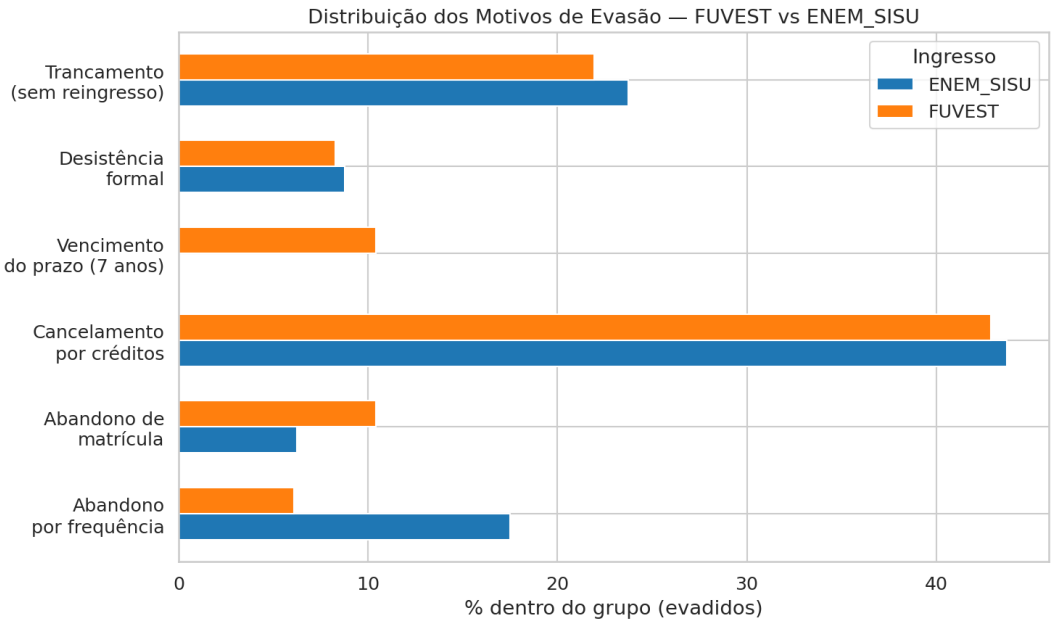

Figura 3: Distribuição dos motivos de evasão entre FUVEST e ENEM_SISU (proporção dentro de cada grupo de evadidos).

3.4 Tempo de Curso

3.4.1 Tempo de Conclusão

Alunos que concluíram levaram, em mediana, 10,2 semestres (FUVEST) e 9,2 semestres (ENEM_SISU). A Figura 4 apresenta a distribuição comparativa para todos os grupos descritivos, e a Figura 5 detalha a densidade para FUVEST e ENEM_SISU.

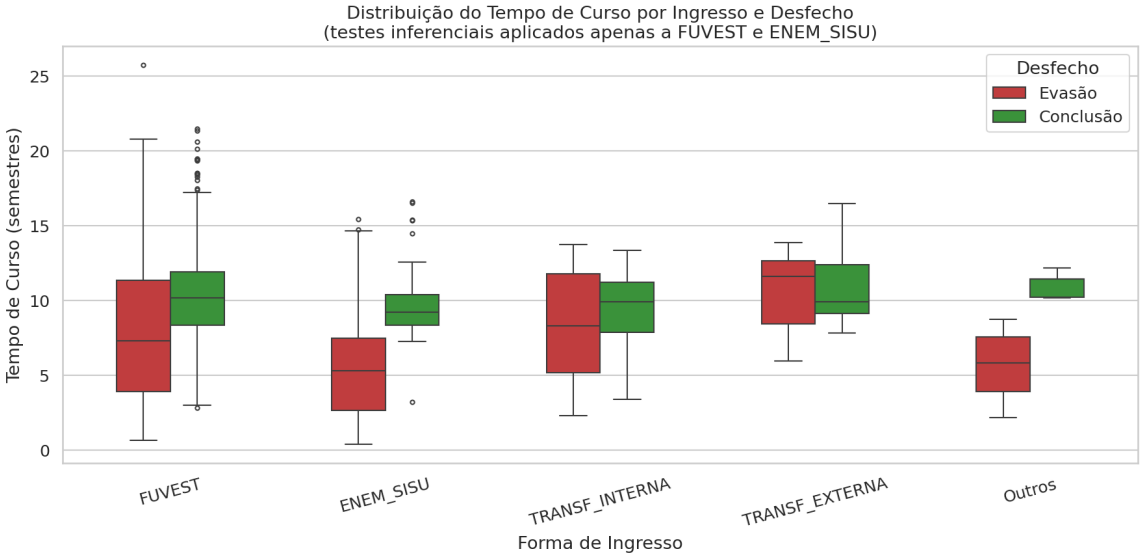

Figura 4: Distribuição do tempo de curso (semestres) por grupo de ingresso e desfecho. Todos os grupos são exibidos para fins descritivos; testes inferenciais aplicados somente a FUVEST e ENEM_SISU.

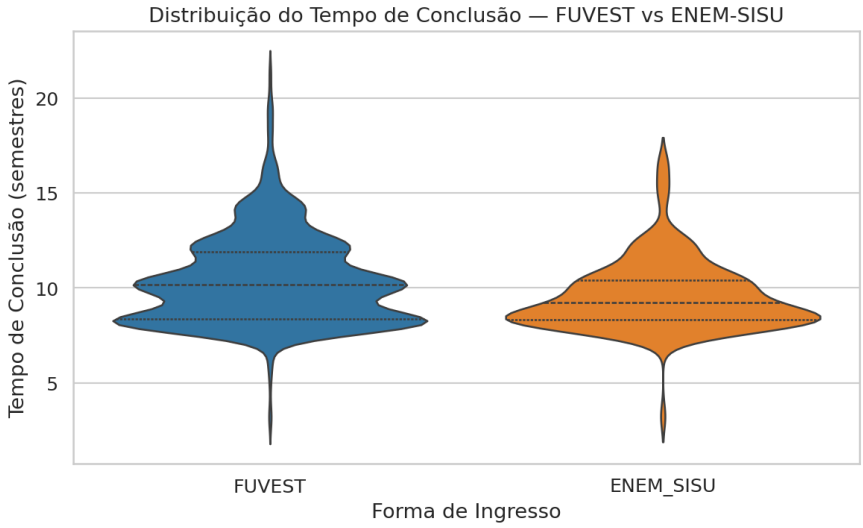

Figura 5: Distribuição do tempo de conclusão (semestres) para FUVEST e ENEM_SISU. As linhas internas representam os quartis.

3.4.2 Tempo até Evasão

Alunos do ENEM_SISU que evadiram saíram mais cedo (mediana de **5,3 semestres**) em comparação aos do FUVEST (mediana de **7,3 semestres**), sugerindo maior vulnerabilidade precoce.

3.5 Créditos Acumulados

A diferença de créditos entre quem concluiu e quem evadiu é marcante: mediana de **188 créditos** para concluintes vs. **38 créditos** para evadidos (Figura 6).

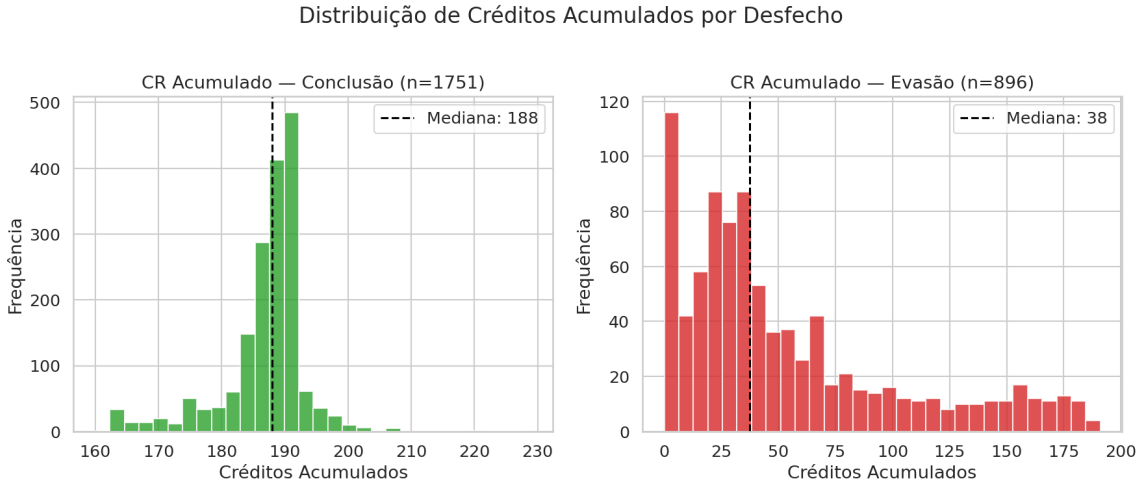

Figura 6: Distribuição de créditos acumulados por desfecho. A linha tracejada indica a mediana de cada grupo.

3.6 Evasão Precoce vs. Tardia

Definiu-se evasão precoce como aquela ocorrida antes de 4 semestres. A Figura 7 apresenta a comparação entre os grupos descritivos relevantes. O grupo ENEM_SISU apresenta maior proporção de evasão precoce (46%) em relação ao FUVEST (33%), reforçando a vulnerabilidade nos primeiros semestres. Os dados de TRANSF_INTERNA e TRANSF_EXTERNA são exibidos de forma descritiva.

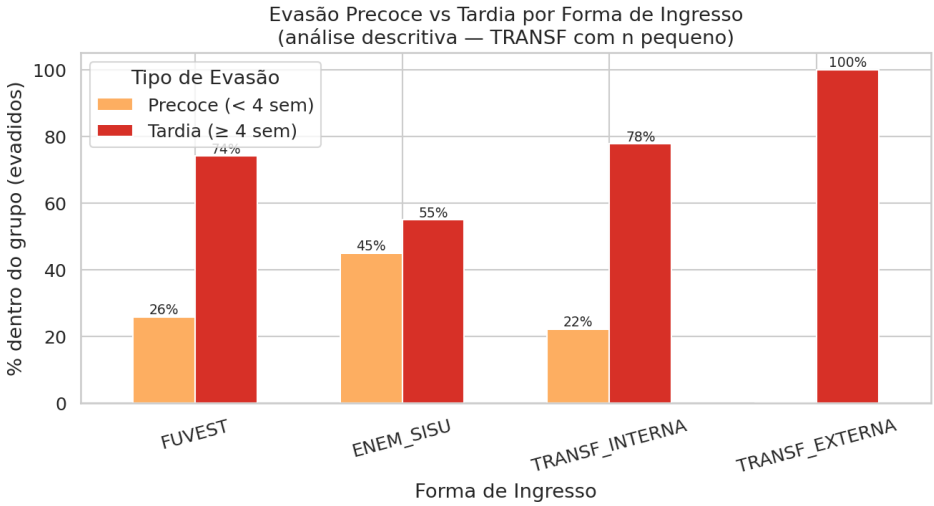

Figura 7: Proporção de evasão precoce (< 4 semestres) e tardia (≥ 4 semestres) por grupo de ingresso, calculada dentro dos evadidos de cada grupo.

3.7 Evolução Temporal por Coorte (2005–2021)

A Figura 8 mostra a evolução geral das taxas de evasão e conclusão por coorte. Observa-se tendência de redução da evasão a partir de 2018, especialmente no FUVEST (de 35% nas coortes de 2007–2010 para 18% em 2018–2020). A Figura 9 apresenta o *heatmap* por coorte e ingresso, e a Figura 10 compara diretamente FUVEST e ENEM_SISU.

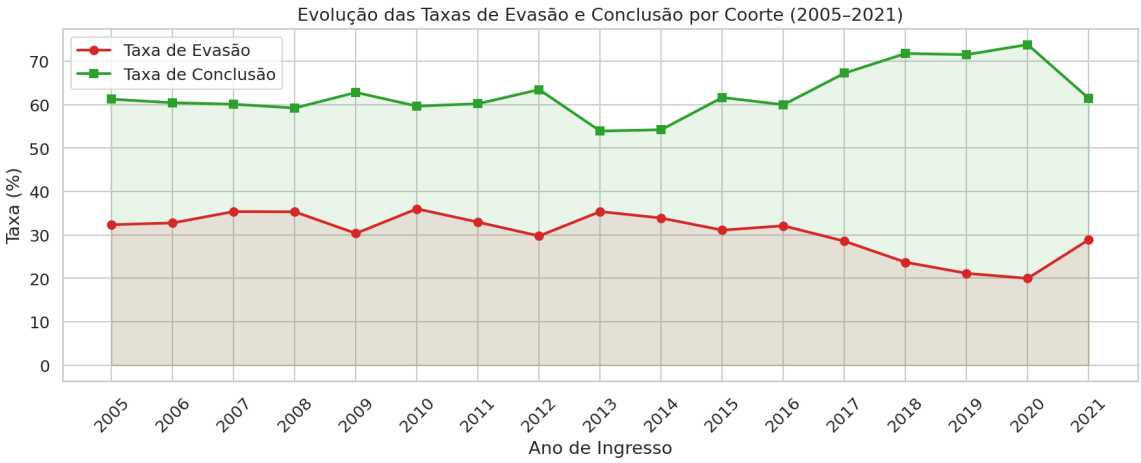

Figura 8: Evolução das taxas de evasão e conclusão por coorte (2005–2021). Coortes de 2022 em diante excluídas por baixo volume.

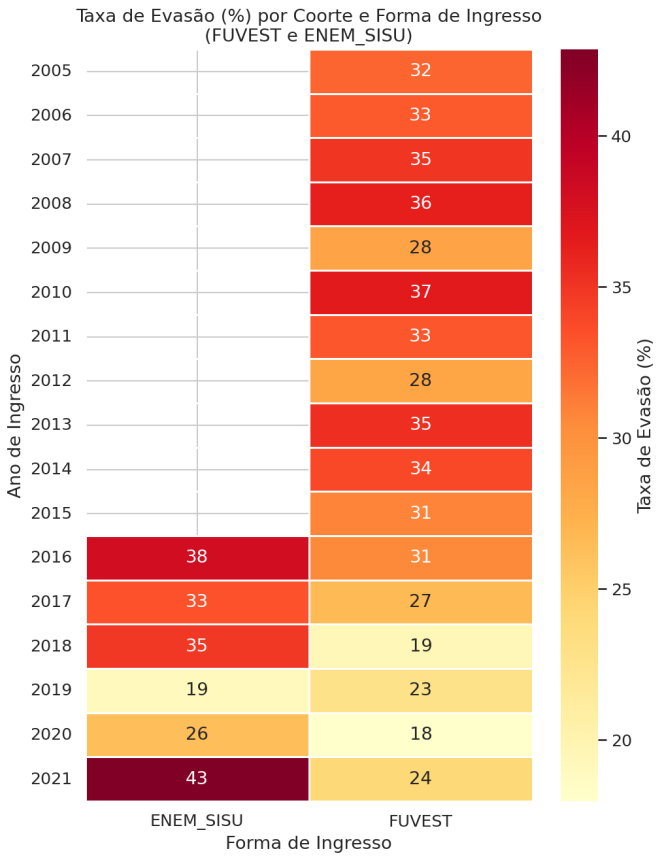

Figura 9: *Heatmap* da taxa de evasão (%) por coorte e grupo de ingresso. Células em branco indicam ausência de dados.

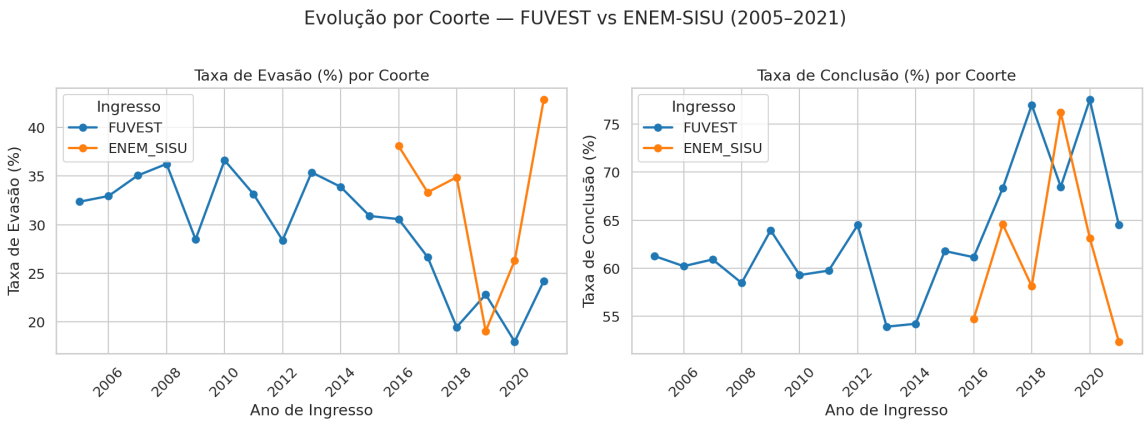

Figura 10: Evolução das taxas de evasão (esq.) e conclusão (dir.) por coorte — FUVEST e ENEM_SISU. ENEM_SISU disponível a partir de 2016.

4 Análise Estatística

4.1 Análise de Sobrevivência — Kaplan-Meier

A Figura 11 apresenta dois painéis. O painel esquerdo mostra as curvas de Kaplan-Meier para FUVEST e ENEM_SISU com intervalos de confiança (análise inferencial). O painel direito exibe as curvas de todos os grupos de forma descritiva, sem IC, com linhas tracejadas para os grupos de menor representatividade.

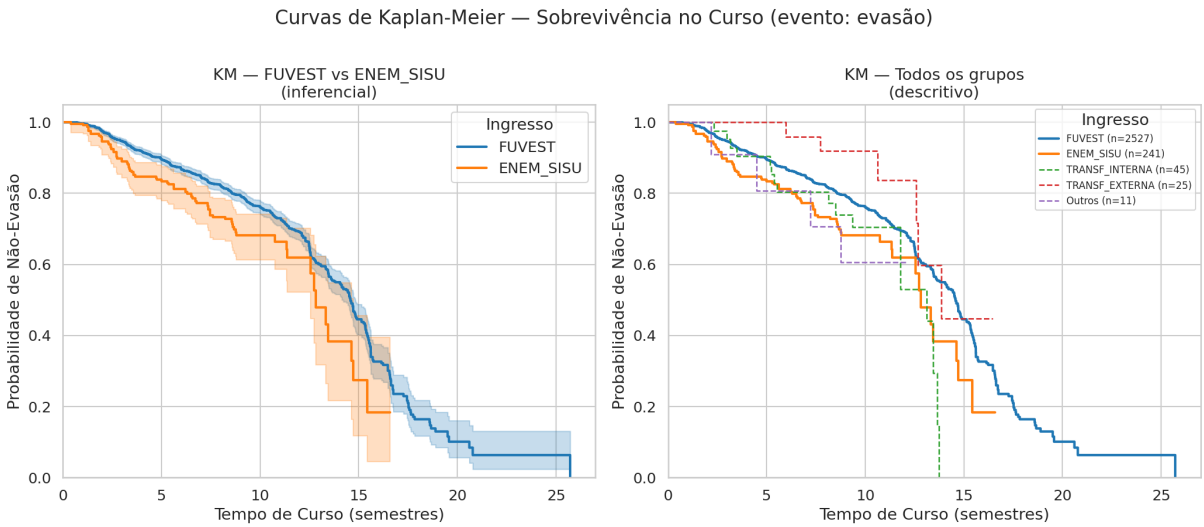

Figura 11: **Esquerda:** Curvas de Kaplan-Meier inferencial com IC 95% para FUVEST e ENEM_SISU. **Direita:** Curvas descritivas para todos os grupos (linhas tracejadas = grupos com n pequeno, sem inferência formal). Evento: evasão; censurado: demais desfechos.

A mediana de sobrevivência foi de **14,6 semestres para FUVEST** e **12,8 semestres para ENEM_SISU**. O **teste log-rank** rejeitou a hipótese de igualdade das curvas ($\chi^2 = 10{,}04$; $p = 0{,}0015$), indicando diferença estatisticamente significativa no padrão temporal de evasão entre os dois grupos.

4.2 Testes de Hipóteses

Os resultados são sumarizados na Tabela 6.

Tabela 6: Resultados dos testes estatísticos (FUVEST vs ENEM_SISU)

Teste	**Comparação**	**Estatística**	**p-valor**	**Decisão**
χ^2	Taxa de evasão	0,326	0,568	Não rejeita H_0
χ^2	Taxa de conclusão	0,060	0,806	Não rejeita H_0
Mann-Whitney U	Tempo de conclusão	134.040	0,0003	Rejeita H_0
Mann-Whitney U	Tempo até evasão	39.957	0,0001	Rejeita H_0
Mann-Whitney U	CR: Conclusão vs Evasão	1.560.938	$< 0{,}001$	Rejeita H_0
Log-rank	Curvas KM	10,040	0,0015	Rejeita H_0

As taxas absolutas de evasão e conclusão **não diferem significativamente** entre FUVEST e ENEM_SISU (χ^2, $p > 0{,}5$). Contudo, o **padrão temporal** difere significativamente: alunos do ENEM_SISU concluem mais rápido (mediana 9,2 vs. 10,2 semestres, $p < 0{,}001$) e, entre os evadidos, saem mais cedo (mediana 5,3 vs. 7,3 semestres, $p < 0{,}001$).

4.3 Regressão Logística

O modelo de regressão logística (restrito a FUVEST e ENEM_SISU) obteve AUC de **0,998** ($\pm 0{,}002$) em validação cruzada, indicando excelente capacidade discriminativa (Tabela 7).

Tabela 7: Coeficientes padronizados da regressão logística (desfecho: evasão)

Preditor	**Coeficiente padronizado**	**Direção**
Ingresso (ENEM_SISU = 1)	$-0{,}275$	Menor probabilidade de evasão
Tempo no curso (semestres)	$+1{,}576$	Maior tempo $\rightarrow$ maior risco
Créditos acumulados	$-8{,}565$	Mais créditos $\rightarrow$ menor risco

O preditor de maior magnitude é **créditos acumulados**, reforçando que o progresso acadêmico precoce é o principal fator protetor. **Nota:** os preditores tempo e créditos são parcialmente endógenos ao desfecho; o modelo quantifica associações, não relações causais.

5 Discussão

Os resultados revelam um panorama nuançado sobre os padrões de conclusão e evasão no curso de Sistemas de Informação da EACH-USP.

Taxas gerais. A taxa de conclusão de 61,5% e de evasão de 31,4.%

Comparação FUVEST vs. ENEM_SISU. A ausência de diferença significativa nas taxas absolutas ($p > 0{,}5$) contraria narrativas que associam o ingresso via ENEM a piores resultados. Contudo, o padrão temporal difere: alunos do ENEM_SISU concluem mais rápido e, quando evadem, o fazem mais cedo, com 46% das evasões nos primeiros

4 semestres (vs. 33% no FUVEST). Isso sugere maior **vulnerabilidade de adaptação inicial**.

Grupos descritivos. TRANSF_EXTERNA apresenta a maior taxa de conclusão (76%), possivelmente associada a alunos com maior maturidade acadêmica. TRANSF_INTERNA apresenta a maior taxa de evasão (40%), podendo refletir dificuldade de adaptação ao novo curso. Esses resultados devem ser interpretados com cautela dado o n pequeno.

Motivos de evasão. O cancelamento por créditos insuficientes (43%) e trancamento sem reingresso (22,5%) indicam que a evasão é predominantemente *passiva*: o aluno vai perdendo o vínculo gradualmente.

Limitações. (i) A base não contém variáveis socioeconômicas; (ii) grupos TRANSF_INTERNA, TRANSF_EXTERNA e Outros têm amostras insuficientes para inferência formal; (iii) coortes 2022–2025 foram excluídas das análises temporais por truncamento à direita.

6 Conclusão

Este estudo analisou 2.849 históricos acadêmicos do curso de Sistemas de Informação da EACH-USP (2005–2025). Os principais achados são:

1. A taxa de conclusão (61,5%) e evasão (31,4%) são comparáveis à média nacional para cursos na área de tecnologia.

2. **FUVEST e ENEM_SISU apresentam taxas absolutas de evasão e conclusão estatisticamente indistinguíveis** (χ^2, $p > 0{,}5$).

3. **O padrão temporal difere:** alunos do ENEM_SISU concluem mais rápido (mediana 9,2 vs. 10,2 semestres) e evadidos saem mais cedo (mediana 5,3 vs. 7,3 semestres), confirmado por Mann-Whitney e log-rank ($p < 0{,}002$).

4. O principal motivo de evasão é o cancelamento administrativo por insuficiência de créditos (43%), indicando abandono gradual.

5. Créditos acumulados é o principal preditor de desfecho na regressão logística, reforçando que o progresso acadêmico precoce é fator protetor.

6. Em análise descritiva, TRANSF_EXTERNA apresenta a maior taxa de conclusão (76%) e TRANSF_INTERNA a maior taxa de evasão (40%), resultados que merecem investigação futura com amostras maiores.

As evidências apontam para a importância de **políticas de acompanhamento nos primeiros semestres**, especialmente para alunos ingressantes pelo ENEM_SISU e transferências internas. Estudos futuros devem incorporar dados socioeconômicos, desempenho por disciplina e variáveis de engajamento institucional.

Apêndice: Código Python da Análise

Carga, pré-processamento e agrupamento de ingressos

```python
"""
Analise de Evasao e Conclusao -- Sistemas de Informacao EACH-USP (2005-2025)
Universidade de Sao Paulo -- Escola de Artes, Ciencias e Humanidades
Professor Orientador: Marcelo Morandini
Autor: Joao Fontanezi
"""
import pandas as pd
import numpy as np

df = pd.read_excel('BASE_ALUNOS_FINAL.xlsx')

# Datas ja vem como datetime via openpyxl
df['DATA_INGRESSO']      = pd.to_datetime(df['DATA_INGRESSO'],      errors='coerce')
df['DATA_ENCERRAMENTO'] = pd.to_datetime(df['DATA_ENCERRAMENTO'], errors='coerce')
df['ANO_INGRESSO']       = df['DATA_INGRESSO'].dt.year
df['TEMPO_SEMESTRES']    = df['TEMPO_CURSO'] / 180
df['CR_ACUMULADO']       = pd.to_numeric(df['CR_ACUMULADO'], errors='coerce')

# Agrupamento: categorias com baixa representatividade -> "Outros"
OUTROS_INGRESSO = {'CONV_PEC_G', 'GRADUADO', 'ENEM_USP', 'OLIMP'}

def agrupar_ingresso(ti):
    if ti in OUTROS_INGRESSO:
        return 'Outros'
    return ti

df['INGRESSO'] = df['TIPO_INGRESSO'].apply(agrupar_ingresso)
INGRESSO_ORDEM = ['FUVEST', 'ENEM_SISU', 'TRANSF_INTERNA', 'TRANSF_EXTERNA', 'Outros']

# Classificacao de desfechos
EVASAO       = {'ABANDONO_FREQUENCIA','ABANDONO_MATRICULA','CANC_CREDITO',
                'CANC_VENCIMENTO','DESISTENCIA','TRANCAMENTO'}
CONTINUA_USP = {'REINGRESSO','TRANSF_INT'}
SAIDA_EXT    = {'TRANSF_EXT','CANC_OUTRA_IES'}

def classificar_desfecho(te):
    if te == 'CONCLUSAO':  return 'Conclusao'
```

```
    if te in EVASAO:        return 'Evasao'
    if te in CONTINUA_USP: return 'Continua na USP'
    if te in SAIDA_EXT:     return 'Saida para outra IES'
    return 'Outros'

df['DESFECHO'] = df['TIPO_ENCERRAMENTO'].apply(classificar_desfecho)
df['EVADIU']   = (df['DESFECHO'] == 'Evasao').astype(int)
df['CONCLUIU'] = (df['DESFECHO'] == 'Conclusao').astype(int)

# Grupos para testes inferenciais e coortes validas
GRUPOS_INFER        = ['FUVEST', 'ENEM_SISU']
df['COORTE_VALIDA'] = df['ANO_INGRESSO'] <= 2021
```

Listing 1: Carga e agrupamento das formas de ingresso

Análise de sobrevivência — Kaplan-Meier com dois painéis

```
from lifelines import KaplanMeierFitter
from lifelines.statistics import logrank_test

# Subconjunto para analise inferencial: apenas FUVEST e ENEM_SISU
df_km = df[df['INGRESSO'].isin(GRUPOS_INFER)].copy()
df_km = df_km[df_km['TEMPO_SEMESTRES'].notna() & (df_km['TEMPO_SEMESTRES
    '] > 0)]

fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# Painel esquerdo: inferencial (FUVEST vs ENEM_SISU, com IC 95%)
kmfs = {}
for grupo in GRUPOS_INFER:
    sub = df_km[df_km['INGRESSO'] == grupo]
    kmf = KaplanMeierFitter()
    kmf.fit(sub['TEMPO_SEMESTRES'],
            event_observed=sub['EVADIU'], label=grupo)
    kmf.plot_survival_function(ax=axes[0], ci_show=True, linewidth=2)
    kmfs[grupo] = (sub['TEMPO_SEMESTRES'], sub['EVADIU'])

# Painel direito: descritivo (todos os grupos, sem IC)
df_km_all = df[df['TEMPO_SEMESTRES'].notna() & (df['TEMPO_SEMESTRES'] >
    0)].copy()
for grupo in INGRESSO_ORDEM:
    sub = df_km_all[df_km_all['INGRESSO'] == grupo]
    if len(sub) < 5: continue
    kmf = KaplanMeierFitter()
    kmf.fit(sub['TEMPO_SEMESTRES'],
            event_observed=sub['EVADIU'],
```

```
            label=f'{grupo} (n={len(sub)})')
    kmf.plot_survival_function(
        ax=axes[1], ci_show=False,
        linewidth=2 if grupo in GRUPOS_INFER else 1.2,
        linestyle='-' if grupo in GRUPOS_INFER else '--')

# Log-rank test: FUVEST vs ENEM_SISU
T1, E1 = kmfs['FUVEST']
T2, E2 = kmfs['ENEM_SISU']
lr = logrank_test(T1, T2, event_observed_A=E1, event_observed_B=E2)
print(f"Log-rank p={lr.p_value:.4f} (stat={lr.test_statistic:.4f})")
```

Listing 2: Kaplan-Meier inferencial e descritivo

Testes de hipóteses e regressão logística

```
from scipy.stats import chi2_contingency, mannwhitneyu
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import cross_val_score

df_inf = df[df['INGRESSO'].isin(GRUPOS_INFER)].copy()

# Qui-quadrado: evasao vs nao-evasao
ct2 = pd.crosstab(df_inf['INGRESSO'],
                  df_inf['DESFECHO'].apply(
                      lambda x: 'Evasao' if x=='Evasao' else 'Nao-Evasao'))
chi2, p, dof, _ = chi2_contingency(ct2)
print(f"chi2 evasao={chi2:.4f}, p={p:.4f}")

# Qui-quadrado: conclusao vs nao-conclusao
ct3 = pd.crosstab(df_inf['INGRESSO'],
                  df_inf['DESFECHO'].apply(
                      lambda x: 'Conclusao' if x=='Conclusao' else 'Nao-Conclusao'))
chi2_c, p_c, _, _ = chi2_contingency(ct3)
print(f"chi2 conclusao={chi2_c:.4f}, p={p_c:.4f}")

# Mann-Whitney: tempo de conclusao
t_fuv_c = df_inf[(df_inf['INGRESSO']=='FUVEST') &
                 (df_inf['DESFECHO']=='Conclusao')]['TEMPO_SEMESTRES'].dropna()
t_ene_c = df_inf[(df_inf['INGRESSO']=='ENEM_SISU') &
                 (df_inf['DESFECHO']=='Conclusao')]['TEMPO_SEMESTRES'].dropna()
```

```python
u1, p1 = mannwhitneyu(t_fuv_c, t_ene_c, alternative='two-sided')
print(f"MW conclusao: U={u1:.0f}, p={p1:.4f}")

# Mann-Whitney: tempo ate evasao
t_fuv_e = df_inf[(df_inf['INGRESSO']=='FUVEST') &
                 (df_inf['DESFECHO']=='Evasao')]['TEMPO_SEMESTRES'].
                    dropna()
t_ene_e = df_inf[(df_inf['INGRESSO']=='ENEM_SISU') &
                 (df_inf['DESFECHO']=='Evasao')]['TEMPO_SEMESTRES'].
                    dropna()
u2, p2 = mannwhitneyu(t_fuv_e, t_ene_e, alternative='two-sided')
print(f"MW evasao:    U={u2:.0f}, p={p2:.4f}")

# Regressao logistica (apenas FUVEST e ENEM_SISU)
df_reg = df[df['INGRESSO'].isin(GRUPOS_INFER) &
            df['DESFECHO'].isin(['Conclusao','Evasao']) &
            df['CR_ACUMULADO'].notna() &
            df['TEMPO_SEMESTRES'].notna()].copy()
df_reg['ING_BIN'] = (df_reg['INGRESSO'] == 'ENEM_SISU').astype(int)
X    = df_reg[['ING_BIN','TEMPO_SEMESTRES','CR_ACUMULADO']].values
y    = df_reg['EVADIU'].values
X_sc = StandardScaler().fit_transform(X)
auc  = cross_val_score(LogisticRegression(max_iter=500), X_sc, y,
                       cv=5, scoring='roc_auc')
print(f"AUC: {auc.mean():.3f} +/- {auc.std():.3f}")
```

Listing 3: Qui-quadrado, Mann-Whitney e regressão logística

Referências

Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282), 457–481.

Mantel, N. (1966). Evaluation of survival data and two new rank order statistics arising in its consideration. *Cancer Chemotherapy Reports*, 50(3), 163–170.